



ESCUELA POLITÉCNICA NACIONAL

FACULTAD DE
INGENIERÍA DE SISTEMAS

ISWD743
BUSINESS INTELLIGENCE

PROYECTO FINAL

**CREACIÓN E IMPLEMENTACIÓN
DE UN MODELO DIMENSIONAL: CASO MOVIES**

ESTUDIANTES:

ÁNGEL DAVID CHUNCHO JIMÉNEZ
ELIATH SEBASTIAN VELASCO CAMPOZANO
KENNY STHEFANO NAVARRETE PRADO
SANTIAGO IVAN MURILLO FONSECA

DOCENTE:

BYRON ORLANDO JARAMILLO VINUEZA

QUITO,
04 DE AGOSTO DE 2025

Contenido

1	Objetivo	3
2	Introducción	3
3	Análisis de la Base de Datos Original	3
4	Diseño del Modelo Dimensional	5
4.1	Tablas de Hechos	5
4.2	Tablas de Dimensiones	6
5	Implementación Técnica	7
5.1	Diseño del Staging Area	7
5.2	Diseño del Data Warehouse	8
5.3	Desarrollo de ETLs con Pentaho Data Integration	8
5.3.1	Ejemplos de ETLs del Staging Area	9
5.3.2	Ejemplos de ETLs del Datawarehouse	10
6	Desarrollo del Dashboard	11
7	Conclusiones	13
8	Recursos	13

1 Objetivo

Diseñar e implementar un modelo dimensional completo basado en la base de datos de películas (movies), aplicando los principios de modelado dimensional para identificar adecuadamente las tablas de hechos y dimensiones, estructurar un esquema estrella o copo de nieve que optimice el análisis de la información, y desarrollar un dashboard funcional que apoye la toma de decisiones en el contexto del negocio de películas.

2 Introducción

En la actualidad, los datos se consideran un recurso muy valioso por lo cual una gestión eficiente de grandes volúmenes de datos se ha convertido en un factor estratégico clave para la toma de decisiones en las organizaciones. En este contexto, el diseño e implementación de data warehouses permite consolidar información desde distintas fuentes, estructurarla de manera analítica y facilitar su exploración mediante herramientas de business intelligence.

El presente informe documenta el desarrollo completo de un proyecto de modelamiento dimensional basado en la base de datos Movies, trabajada durante el curso. Esta base contiene información relacionada con películas, usuarios, ratings, géneros, entre otros aspectos relevantes del negocio de alquiler de películas.

3 Análisis de la Base de Datos Original

La base de datos original, movies, corresponde a un sistema transaccional para un negocio de renta de películas. Está diseñada para gestionar información sobre películas, actores, clientes, inventario, pagos y alquileres, entre otros elementos clave del negocio.

Estructura General

El diagrama entidad-relación se encuentra en la Figura 2, donde se identifican múltiples tablas principales que representan entidades del negocio, las cuales son:

- **film:** contiene los detalles de cada película (título, duración, idioma, etc.).
- **actor, film_actor:** representan a los actores y su participación en películas.
- **category, film_category:** categorías de las películas (acción, comedia, etc.).
- **customer, address, city, country:** información sobre los clientes y su localización.
- **inventory, store, staff:** control del inventario de películas en tiendas y personal a cargo.
- **rental, payment:** representan las transacciones de arriendo y los pagos realizados.



Figura 1: Diagrama entidad-relación que representa la estructura lógica de movies.

4 Diseño del Modelo Dimensional

El diseño dimensional implementado para el data warehouse de la base *movies* sigue un esquema en *copo de nieve*, el cual extiende el modelo estrella tradicional mediante la normalización de algunas dimensiones, como en este caso sucedió con la dimension geography. Este enfoque fue elegido para mantener la integridad referencial, reducir redundancias y facilitar la trazabilidad de atributos relacionados entre entidades.

La Figura 2 ilustra la arquitectura del modelo dimensional diseñado:




Figura 2: Diagrama del modelo dimensional propuesto, en esquema copo de nieve.

4.1 Tablas de Hechos

fact_rental

Registra los eventos de arriendo y pago de películas. Para esta tabla se ha definido la métrica `payment_amount`.

- **customer_id:** cliente que realiza el arriendo
- **staff_id:** empleado que atiende
- **film_id:** película alquilada
- **payment_date_id:** fecha de pago
- **payment_amount:** monto del pago realizado

- **fecha_carga:** marca de carga del dato en el dwh

fact_inventory

Representa la disponibilidad y movimiento de películas en las tiendas, además se tiene la métrica cantidad.

- **store_id:** tienda correspondiente
- **film_id:** referencia a la película
- **cantidad:** cantidad de películas por inventario de las tiendas
- **rental_date_id:** fecha de arriendo de la película
- **return_date_id:** fecha de devolución de la película
- **fecha_carga:** marca de carga del dato en el dwh

4.2 Tablas de Dimensiones

dim_film

Contiene atributos descriptivos de las películas: título, año de lanzamiento, tarifa de alquiler, duración, clasificación, categoría e idioma.

dim_actor

Incluye información de actores relacionados con las películas.

dim_customer

Registra información del cliente: nombre completo, estado activo y dirección mediante dim_geography.

dim_staff

Contiene los datos del personal, su tienda de trabajo y estado de actividad.

dim_store

Registra las tiendas disponibles y su ubicación geográfica.

dim_geography

Contiene los atributos geográficos comunes para clientes, empleados y tiendas: país, ciudad, dirección, código postal.

dim_tiempo

Permite desglosar los hechos en múltiples niveles de granularidad (día, mes, trimestre, etc.)

5 Implementación Técnica

5.1 Diseño del Staging Area

El staging area sirvió como zona intermedia para la depuración, transformación y validación de datos provenientes del sistema transaccional, es decir, refleja temporalmente las estructuras de la base original, permitiendo trabajar sobre los datos sin alterar su origen.

En primer lugar, partiendo de la base original, se eliminaron relaciones entre tablas, tanto llaves primarias como llaves foráneas; también se eliminaron restricciones, vistas, funciones, índices, es decir, solo se utilizarán las tablas con sus atributos, para lo cual también se cambió el tipo de dato a varchar para los siguientes casos:

- enums
- tsvector
- text[]

Además, se añadió un campo de control denominado `fecha_carga`. En la Figura 3 se aprecia el diagrama del resultado final del staging area.




Figura 3: Diagrama del staging area resultante.

5.2 Diseño del Data Warehouse

El Data Warehouse fue estructurado con base en el modelo dimensional con esquema de copo de nieve descrito previamente, en el cual se proponen dos tablas de hecho y siete tablas de dimensiones junto con sus respectivas relaciones.



Figura 4: Diagrama de la implementación del datawarehouse.

5.3 Desarrollo de ETLs con Pentaho Data Integration

La carga y transformación de los datos se realizó utilizando la herramienta Pentaho Data Integration (PDI), en la cual se definieron los flujos de trabajo de tipo ETL (Extract, Transform, Load). Mediante las transformaciones se extraen los datos desde las tablas transaccionales, se unifican y enriquecen los datos; por ejemplo, para el caso del actor se concatenó el nombre en el atributo full_name, además se añade el campo de control fecha_carga para evitar duplicidad en la carga y registrar la fecha de inserción.

5.3.1 Ejemplos de ETLs del Staging Area




Figura 5: Transformación para cargar datos a la tabla actor del staging area.




Figura 6: Transformación para cargar datos a la tabla rental del staging area.

5.3.2 Ejemplos de ETLs del Datawarehouse




Figura 7: Transformación para cargar datos a la tabla de hecho inventory.




Figura 8: Transformación para cargar datos a la tabla de dimensión tiempo.

6 Desarrollo del Dashboard

La visualización final de los datos según las dimensiones de interés para el análisis del negocio, se lo realizó utilizando la herramienta de Power BI. Esta plataforma es muy efectiva para el propósito del proyecto, proporcionando gráficos analíticos como los de barras y columnas agrupadas, gráficos de pastel, filtros para segmentar datos como el tiempo, gráficos de líneas, mapas, etc.




Figura 9: Dashboard realizado en Power BI para el datawarehouse de Movies.

El dashboard consta de dos secciones principales: los gráficos de título amarillo y los gráficos de título violeta.

Los primeros hacen referencia a datos relacionados con los ingresos (payment_amount de fact_rental), tomando en cuenta las dimensiones de tiempo, store, customer y geography. Por otro lado, los segundos se refieren a datos relacionados con la cantidad de alquileres (count de rental_date_id de fact_inventory), tomando en cuenta las dimensiones de film, actor y store.

Algunos de estos gráficos necesitaron de unos parámetros extra, aparte de los atributos base de cada tabla. Por ejemplo, para el gráfico de barras de categoría/película se creó una jerarquía en la dimensión film; dicha categoría está compuesta por categoría y título (en ese orden). De esa forma se puede navegar por los niveles de la jerarquía para observar tanto las categorías más alquiladas como las películas más alquiladas.




Figura 10: Visualización de las categorías de películas más alquiladas (nivel de Category en la jerarquía).



Figura 11: Visualización de las películas más alquiladas (nivel de Title en la jerarquía).

Otro caso especial es el del gráfico de barras que indica los actores con un mayor número de alquileres. Para obtener estos datos, se creó una medida personalizada con DAX en la tabla dim_actor, cuya fórmula es la siguiente:

```
Alquileres totales por actor = CALCULATE(
    COUNT('public fact_inventory'[rental_date_id]),
    TREATAS(VALUE('public dim_actor'[film_id]), 'public fact_inventory'[film_id])
)
```

Con esta medida se consigue listar a los actores con más alquileres totales.




Figura 12: Visualización de los actores con un mayor número de alquileres.

Finalmente, en la parte superior derecha del dashboard, se tiene una sección general para visualizar los ingresos totales respecto a un criterio seleccionado a partir de los gráficos y visualizaciones que se disponene (se muestran todos los ingresos históricos en caso de no seleccionar nada). Adicionalmente, se tienen 2 apartados para segmentar el tiempo: uno dispone de particiones en año, trimestre, mes y día; el segundo es un control más extenso, permitiendo colocar un rango de fechas específico, y no solo un cierto periodo de tiempo respecto a la partición de tiempo antes mencionada.

7 Conclusiones

El desarrollo de este proyecto permitió aplicar de manera práctica los conceptos fundamentales del modelado dimensional, partiendo del análisis de una base de datos transaccional hasta la implementación de un data warehouse funcional. El diseño adoptado, basado en un esquema de copo de nieve, facilitó la normalización de ciertas dimensiones clave como geografía y actores; sin embargo, este enfoque también aumentó la complejidad del sistema, ya que las transformaciones requirieron de joins para su correcta relación. Se recomienda realizar un análisis de los tipos de datos para detectar posibles errores tempranos al momento de crear los ETLs o a su vez verificar que estos tipos puedan ser cambiados en la transformación.

8 Recursos

En el enlace a continuación se encuentra el repositorio del proyecto, en el cual se alojan los scripts correspondientes a cada área, así como los ETLs, diagramas y modelos generados.

Repositorio: https://github.com/Demonkinng/BI_proyecto_movies.git